

概率论

TimeMachine

2022 年 9 月 8 日

目录

| | |
|------------------------------|----------|
| 第一章 条件概率与独立性 | 1 |
| 1.1 两种概型与概率空间的简单介绍 | 1 |
| 1.1.1 古典概型 | 1 |
| 1.1.2 几何概型 | 1 |
| 1.1.3 概率空间 | 1 |
| 1.2 定义和链式法则 | 2 |
| 1.3 全概率公式 | 2 |
| 1.4 贝叶斯公式 | 3 |
| 1.5 事件独立性 | 3 |
| 1.5.1 两个事件的独立性 | 3 |
| 1.5.2 多个事件的独立性 | 4 |
| 第二章 随机变量 | 5 |
| 2.1 随机变量的概念 | 5 |
| 2.2 离散型随机变量 | 5 |
| 2.3 分布函数与连续型随机向量 | 6 |
| 2.3.1 分布函数 | 6 |
| 2.3.2 连续型随机变量 | 7 |
| 第三章 随机向量 | 9 |
| 3.1 随机向量 | 9 |
| 3.2 离散型随机向量 | 9 |
| 3.3 n 元分布函数 | 10 |
| 3.4 连续型随机向量 | 11 |

| | |
|--------------------------------------|-----------|
| 第四章 条件分布与独立性 | 13 |
| 4.1 随机变量的独立性 | 13 |
| 4.2 离散型随机变量的独立性 | 13 |
| 4.3 连续型随机变量的独立性 | 14 |
| 4.4 离散型随机变量的条件分布 | 15 |
| 4.5 连续性随机变量的条件分布 | 15 |
| 第五章 数学期望 | 17 |
| 5.1 离散型随机变量的数学期望 | 17 |
| 5.2 连续型随机变量的数学期望 | 17 |
| 5.3 一般随机变量的数学期望 | 18 |
| 5.4 数学期望的性质 | 18 |
| 5.5 条件期望 | 21 |
| 5.6 全期望公式 | 21 |
| 第六章 方差、协方差与相关系数 | 23 |
| 6.1 方差及其性质 | 23 |
| 6.1.1 方差 | 23 |
| 6.1.2 切比雪夫 (Chebyshev) 不等式 | 23 |
| 6.1.3 方差的性质 | 24 |
| 6.2 协方差及其性质 | 26 |
| 6.2.1 协方差 | 26 |
| 6.2.2 协方差的性质 | 26 |
| 6.3 Pearson 相关系数及其性质 | 28 |
| 6.3.1 Pearson 相关系数 | 28 |
| 6.3.2 Pearson 相关系数的性质 | 28 |
| 第七章 矩 | 30 |
| 第八章 特征函数 | 31 |
| 8.1 常见特征函数 | 31 |
| 8.1.1 退化分布 | 31 |
| 8.1.2 二项分布 | 31 |
| 8.1.3 泊松分布 | 31 |
| 8.1.4 均匀分布 | 32 |

| | |
|--|-----------|
| 目 录 | iii |
| 8.1.5 正态分布 | 32 |
| 8.2 可微性 | 33 |
| 8.2.1 预备知识 | 33 |
| 8.2.2 可微性 | 34 |
| 第九章 概率极限定理 | 36 |
| 9.1 Bernoulli 大数律 | 36 |
| 9.1.1 内容 | 36 |
| 9.2 De Moivre-Laplace 中心极限定理 | 36 |
| 9.2.1 内容 | 36 |
| 9.3 Poisson 极限定理 | 36 |
| 9.4 Chebyshev 大数律 | 37 |
| 9.4.1 内容 | 37 |
| 9.4.2 推广 | 37 |
| 9.4.3 回忆 Chebyshev 不等式 | 37 |
| 9.5 Khinchine 大数律 | 38 |
| 9.5.1 内容 | 38 |
| 9.6 Levy-Feller 中心极限定理 | 38 |
| 9.6.1 内容 | 38 |
| 9.6.2 意义 | 38 |
| 9.6.3 证明 | 38 |
| 9.7 Lyapunov 中心极限定理 | 39 |
| 9.7.1 内容 | 39 |
| 第十章 概率论的收敛 | 40 |
| 10.1 依概率收敛 | 40 |
| 10.1.1 定义 | 40 |
| 10.1.2 敛散性判别法则 | 40 |
| 10.1.3 性质 | 40 |
| 10.2 依分布收敛 | 40 |
| 10.2.1 定义 | 40 |
| 10.2.2 依概率收敛强于依分布收敛 | 41 |
| 10.2.3 敛散性判别法则 | 42 |

| | |
|--|-----------|
| 第十一章 正态分布 | 44 |
| 11.1 一元正态分布密度函数的规范性 | 44 |
| 11.2 二元正态分布的边际分布与线性变换 | 45 |
| 11.2.1 二元正态分布的边际分布 | 45 |
| 11.2.2 二元正态分布的线性变换 | 46 |
| 11.3 二元正态分布的条件分布和独立性 | 47 |
| 11.3.1 二元正态分布的条件分布 | 47 |
| 11.3.2 二元正态分布的独立性等价条件 | 47 |
| 11.4 一元正态分布的期望与方差 | 49 |
| 11.5 二元正态分布的协方差、Pearson 相关系数 | 50 |

第一章 条件概率与独立性

1.1 两种概型与概率空间的简单介绍

1.1.1 古典概型

古典概型的特征：

1、样本空间中样本点有限， $\Omega = \{\omega_1, \omega_2, \dots, \omega_n\}$

2、各基本事件等可能，即 $P(\omega) = \frac{1}{n}$

古典概型的计算：

$$P(A) = \frac{m}{n} = \frac{\text{A 包含的样本点数}}{\text{样本空间中样本点总数}}$$

1.1.2 几何概型

几何概型的特征：

1、样本空间中样本点无限

2、样本点落在等测度 (长度、面积、体积 ...) 区域的概率相等

几何概型的计算：($A_g = \{\text{任取样本点, 位于区域 } g \in \Omega \text{ 的概率}\}$)

$$P(A_g) = \frac{g \text{ 的测度}}{\Omega \text{ 的测度}}$$

1.1.3 概率空间

一个概率空间可以表示为 (Ω, \mathcal{F}, P) ，其中

Ω ：样本空间，即样本点 ω 的全体。有 $\Omega = \{\omega_1, \omega_2, \dots\}$ 。

\mathcal{F} ：事件域，包括所有的事件。

P ：定义的概率。概率的公理化定义如下：

(1)(非负性) $\forall A \in \mathcal{F}, P(A) \geq 0$

(2)(规范性) $P(\Omega) = 1$

(3)(可列可加性) $A_i \cap A_j = \emptyset, i \neq j$ (即 A_1, \dots, A_n, \dots 为两两不相容的事件)

$$P\left(\sum_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} P(A_n)$$

1.2 定义和链式法则

条件概率 $P(A|B)$: 事件 B 发生条件下事件 A 发生的概率, 称为事件 A 关于事件 B 的**条件概率** (conditional probability)

有基本公式:

$$P(A|B) = \frac{P(AB)}{P(B)}$$

也可以表示为**链式法则** (乘法公式) 的形式:

$$P(AB) = P(A|B)P(B)$$

推广到 n 个事件, 有链式法则:

$$P\left(\prod_{i=1}^n A_i\right) = \prod_{i=1}^n P\left(A_i \middle| \prod_{j=1}^{i-1} A_j\right)$$

特别定义 $a > b$ 时, $\prod_{i=a}^b A_i$ 为必然事件。或者这样写可能更容易看懂:

$$P(A_1 A_2 \cdots A_n) = P(A_1) \cdot P(A_2 | A_1) \cdot P(A_3 | A_1 A_2) \cdots P(A_n | A_1 A_2 \cdots A_{n-1})$$

1.3 全概率公式

在概率空间 (Ω, \mathcal{F}, P) 中, 若 $\{A_1, A_2, \dots, A_n\} (n < \infty \text{ 或 } n = \infty)$ 构成 Ω 的一个**分割** (完备事件组), 满足:

(1) A_i 两两互不相容 (不可能同时发生), 且 $P(A_i) > 0$

(2) $\sum_{i=1}^{\infty} A_i = \Omega$

则有**全概率** (total probability) 公式: $\forall B \in \mathcal{F}$, 有

$$P(B) = \sum_{i=1}^n P(A_i)P(B|A_i)$$

证明：

$$P(B) = P(B\Omega) \quad (1.1)$$

$$= P\left(B \sum_{i=1}^n A_i\right) \quad (1.2)$$

$$= P\left(\sum_{i=1}^n BA_i\right) \quad (1.3)$$

$$= \sum_{i=1}^n P(BA_i) \quad (1.4)$$

$$= \sum_{i=1}^n P(A_i)P(B|A_i) \quad (1.5)$$

1.4 贝叶斯公式

贝叶斯 (Bayes) 公式如下：

$$P(A_i|B) = \frac{P(A_i)P(B|A_i)}{\sum_{k=1}^{\infty} P(A_k)P(B|A_k)}$$

证明： $P(A_i|B) = \frac{P(A_iB)}{P(B)}$ ，分子用链式法则展开，分母用全概率公式展开。

深入了解条件概率的意义：

$P(A_i)$: 不知 B 是否发生，称为先验 (priori) 概率

$P(A_i|B)$: 以 B 发生为已知条件，称为后验 (posteriori) 概率

1.5 事件独立性

1.5.1 两个事件的独立性

定义：事件 A 与事件 B 相互独立 (统计独立, statistical independence)，如果满足

$$P(AB) = P(A) \cdot P(B)$$

因为此时有

$$P(A|B) = \frac{P(AB)}{P(B)} = P(A)$$

且

$$P(B|A) = \frac{P(AB)}{P(A)} = P(B)$$

如果 A 与 B 不相互独立, 也称为**统计相依** (statistical dependence)

1.5.2 多个事件的独立性

对于一组事件 A_1, A_2, \dots, A_n , 存在两两独立和整体的相互独立两种概念。不妨先以三个事件 A, B, C 为例进行研究。

两两独立: 即 A 与 B 相互独立, B 与 C 相互独立, C 与 A 相互独立。

$$\begin{cases} P(AB) = P(A) \cdot P(B) \\ P(AC) = P(A) \cdot P(C) \\ P(BC) = P(B) \cdot P(C) \end{cases}$$

整体相互独立: 即满足

$$P(ABC) = P(A) \cdot P(B) \cdot P(C)$$

推广到 n 个事件, A_1, A_2, \dots, A_n 相互独立需要满足: $\forall r < n$, A_1, A_2, \dots, A_n 中任意 r 个事件都相互独立, 且

$$P\left(\prod_{i=1}^n A_i\right) = \prod_{i=1}^n P(A_i)$$

或者直接这么定义: A_1, A_2, \dots, A_n 相互独立, 如果

$$\forall r \leq n (r \in \mathbb{N}_+), P\left(\prod_{i=1}^r A_{n_i}\right) = \prod_{i=1}^r P(A_{n_i}), 1 \leq n_1 < n_2 < \dots < n_r \leq n$$

第二章 随机变量

2.1 随机变量的概念

定义概率空间 (Ω, \mathcal{F}, P) 上的单值实函数 $\xi(\omega)$ ，即

$$\xi : \Omega \rightarrow \mathbb{R}$$

还要求 $\xi(\omega)$ 的任意取值组合对应的样本点集合构成的事件在事件域 \mathcal{F} 中，这样就可以称 $\xi(\omega)$ 为 **随机变量** (random variable)

实在太过抽象，暂且可以认为随机变量就是一个随机值。

2.2 离散型随机变量

离散型随机变量：随机变量 ξ 可取的值至多可列个。

分布列 (distribution sequence):

$$\begin{bmatrix} x_1 & x_2 & \cdots & x_n & \cdots \\ p(x_1) & p(x_2) & \cdots & p(x_n) & \cdots \end{bmatrix}$$

第一行是 ξ 可能取的值，第二行是 ξ 取这些值的概率。

分布列有性质：

$$p(x_i) > 0, i = 1, 2, \dots$$

$$\sum_{i=1}^{\infty} p(x_i) = 1$$

对一些常见离散型随机变量举例如下：

(1) **退化 (degenerate) 分布**

$$\begin{bmatrix} c \\ 1 \end{bmatrix}$$

(2) 两点分布 (伯努利分布, bernoulli distribution)

$$\begin{bmatrix} 1 & 0 \\ p & 1-p \end{bmatrix}, p \in (0, 1)$$

(3) 二项 (binomial) 分布

$$P(\xi = k) = \binom{n}{k} p^k (1-p)^{n-k}, p \in (0, 1), k = 0, 1, \dots, n$$

记为 $\xi \sim B(n, p)$

(4) 泊松 (Poisson) 分布

$$P(\xi = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \lambda > 0, k \in \mathbb{N}$$

记为 $\xi \sim \mathcal{P}(\lambda)$

(5) 几何 (geometry) 分布

$$P(\xi = k) = p(1-p)^{k-1}, p \in (0, 1), k \in \mathbb{N}_+$$

(6) 超几何 (hypergeometry) 分布

$$P(\xi = k) = \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}}, n \leq N, M \leq N, k = 0, 1, \dots, \min\{n, M\}$$

2.3 分布函数与连续型随机向量

2.3.1 分布函数

$$F(x) = P(\xi \leq x), -\infty < x < +\infty$$

为随机变量 $\xi(\omega)$ 的分布函数 (distribution function)

分布函数有公理化定义:

(1) 单调递增 (不要求严格): $a < b, F(a) \leq F(b)$

(2) $\lim_{x \rightarrow -\infty} F(x) = 0, \lim_{x \rightarrow +\infty} F(x) = 1$

(3) 处处左极限存在，右连续。即

$$\exists F(x-0) = \lim_{h \rightarrow 0^+} F(x-h)$$

$$F(x+0) = \lim_{h \rightarrow 0^+} F(x+h) = F(x)$$

注意，如果修改分布函数定义为

$$F(x) = P(\xi < x), -\infty < x < +\infty$$

那么 (3) 应该修改为处处右极限存在，左连续。

2.3.2 连续型随机变量

\exists 一个非负的可积函数 $p(x)$ s.t. 分布函数 $F(x)$ 满足

$$F(x) = \int_{-\infty}^x p(y) dy, -\infty < x < +\infty$$

则以 $F(X)$ 为分布函数的 ξ 称为**连续型** (continuous) 随机变量。

$p(x)$ 称为 ξ 的概率密度函数，简称 **密度函数** (density function)

$F(x)$ 是一个变上限积分，可以证明，在 $p(x)$ 的连续点处，有

$$F'(x) = p(x)$$

ξ 落于 $(a, b]$ 的概率为

$$P(a < \xi \leq b) = F(b) - F(a) \quad (2.1)$$

$$= \int_{-\infty}^b p(y) dy - \int_{-\infty}^a p(y) dy \quad (2.2)$$

$$= \int_a^b p(y) dy \quad (2.3)$$

然而需注意，联系几何概型有类似结论：

$$P(\xi = c) = F(c) - \lim_{h \rightarrow 0^+} F(c-h) \quad (2.4)$$

$$= \lim_{h \rightarrow 0^+} \int_{c-h}^c p(y) dy = 0 \quad (2.5)$$

类似离散型随机变量，连续性随机变量的密度函数有如下性质：

(1) 非负性

$$p(x) \geq 0$$

(2) 规范性

$$\int_{-\infty}^{+\infty} p(x)dx = 1$$

注意，随机变量包括连续型随机变量和离散型随机变量，但随机变量并不总是连续性随机变量或离散型随机变量。如

$$F(x) = \begin{cases} 0, & x < 0 \\ \frac{1+x}{2}, & 0 \leq x < 1 \\ 1, & x \geq 1 \end{cases}$$

根据分布函数的公理化定义可以判断它确实是一个分布函数。但是对应的随机变量取值在 $[\frac{1}{2}, 1)$ ，取值并不可列，因此不是离散型随机变量。它也不是连续型随机变量，因为 $F(x)$ 不连续，比如可以看出应有 $P(\xi = 0) = \frac{1}{2}$ ，与连续性随机变量 $P(\xi = c) = 0$ 的性质矛盾。

常见连续性随机变量举例：

(1) 均匀 (uniform) 分布

$$p(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{其他.} \end{cases}$$

记作 $\xi \sim U(a, b)$

(2) 一元正态 (normal) 分布

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad -\infty < x < \infty, \quad \sigma > 0$$

记作 $\xi \sim N(\mu, \sigma^2)$

(3) 指数 (exponential) 分布

$$p(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0 \end{cases} \quad \lambda > 0$$

记作 $\xi \sim \exp(\lambda)$

第三章 随机向量

3.1 随机向量

在同一概率空间 (Ω, \mathcal{F}, P) 上, 有随机变量 $\xi_1(\omega), \xi_2(\omega), \dots, \xi_n(\omega)$ 称

$$\xi(\omega) = (\xi_1(\omega), \xi_2(\omega), \dots, \xi_n(\omega))$$

为 n 维随机向量。

3.2 离散型随机向量

考虑离散型随机向量 (ξ, η) , 其联合分布为:

$$P(\xi = x_i, \eta = y_j) = p_{ij}$$

其边际分布为:

$$P(\xi = x_i) = p_{i\cdot} = \sum_j p_{ij}$$

$$P(\eta = y_j) = p_{\cdot j} = \sum_i p_{ij}$$

其分布列可以这么画:

| $\xi \backslash \eta$ | y_1 | y_2 | \cdots | y_n | \cdots | $p_{i\cdot}$ |
|-----------------------|---------------|---------------|----------|---------------|----------|--------------|
| x_1 | p_{11} | p_{11} | \cdots | p_{1n} | \cdots | $p_{1\cdot}$ |
| x_2 | p_{21} | p_{22} | \cdots | p_{2n} | \cdots | $p_{2\cdot}$ |
| \vdots | \vdots | \vdots | \vdots | \vdots | \vdots | \vdots |
| x_m | p_{m1} | p_{m2} | \cdots | p_{mn} | \cdots | $p_{m\cdot}$ |
| \vdots | \vdots | \vdots | \vdots | \vdots | \vdots | \vdots |
| $p_{\cdot j}$ | $p_{\cdot 1}$ | $p_{\cdot 2}$ | \vdots | $p_{\cdot n}$ | \vdots | |

给出一道练习用的例题：

口袋中有 2 个白球 3 个黑球，连取两次，每次任取一球. 设 ξ 为第一次得白球数， η 为第二次得白球数. 对 (1) 有放回，(2) 无放回两种情况，分别求 (ξ, η) 的联合分布.

解：(1)

$$P(\xi = 0, \eta = 0) = P(\xi = 0)P(\eta = 0) = \frac{3}{5} \cdot \frac{3}{5}$$

同理

$$P(\xi = 0, \eta = 1) = \frac{3}{5} \cdot \frac{2}{5}$$

$$P(\xi = 1, \eta = 0) = \frac{2}{5} \cdot \frac{3}{5}$$

$$P(\xi = 1, \eta = 1) = \frac{2}{5} \cdot \frac{2}{5}$$

得

| $\xi \backslash \eta$ | 0 | 1 | $p_{i \cdot}$ |
|-----------------------|---------------------------------|---------------------------------|---------------|
| 0 | $\frac{3}{5} \cdot \frac{3}{5}$ | $\frac{3}{5} \cdot \frac{2}{5}$ | $\frac{3}{5}$ |
| 1 | $\frac{2}{5} \cdot \frac{3}{5}$ | $\frac{2}{5} \cdot \frac{2}{5}$ | $\frac{2}{5}$ |
| $p_{\cdot j}$ | $\frac{3}{5}$ | $\frac{2}{5}$ | |

(2)

| $\xi \backslash \eta$ | 0 | 1 | $p_{i \cdot}$ |
|-----------------------|---------------------------------|---------------------------------|---------------|
| 0 | $\frac{3}{5} \cdot \frac{2}{4}$ | $\frac{3}{5} \cdot \frac{2}{4}$ | $\frac{3}{5}$ |
| 1 | $\frac{2}{5} \cdot \frac{3}{4}$ | $\frac{2}{5} \cdot \frac{1}{4}$ | $\frac{2}{5}$ |
| $p_{\cdot j}$ | $\frac{3}{5}$ | $\frac{2}{5}$ | |

3.3 n 元分布函数

$\forall (x_1, \dots, x_n) \in \mathbf{R}^n$, 称 n 元函数

$$F(x_1, \dots, x_n) = P(\xi_1(\omega) \leq x_1, \xi_2(\omega) \leq x_2, \dots, \xi_n(\omega) \leq x_n)$$

为随机向量 $\xi(\omega) = (\xi_1(\omega), \xi_2(\omega), \dots, \xi_n(\omega))$ 的 (联合) 分布函数.

以二元联合分布函数为例，其有性质：

(1) 对每个变量单调递增 (不严格)

(2) 对每个变量右连续，左极限存在

(3) $\forall (x, y)$

$$F(x, -\infty) = 0, \quad F(-\infty, y) = 0, \quad F(\infty, \infty) = 1$$

$$(4) \forall a_1, a_2, b_1, b_2 \in R, a_1 < b_1, a_2 < b_2$$

$$F(b_1, b_2) - F(a_1, b_2) - F(b_1, a_2) + F(a_1, a_2) \geq 0$$

考虑边际分布函数 $F_\xi(x)$ 与 $F_\eta(y)$

$$F_\xi(x) = P(\xi < x) \quad (3.1)$$

$$= P(\xi < x, -\infty < y < +\infty) \quad (3.2)$$

$$= F(x, +\infty) \quad (3.3)$$

同理 $F_\eta(y) = F(+\infty, y)$

3.4 连续型随机向量

若存在 n 元可积的非负函数 $p(x_1, \dots, x_n)$, 使 n 元分布函数可表示为

$$F(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_n} p(y_1, \dots, y_n) dy_1 \cdots dy_n$$

则称它是连续型分布, 并称 $p(x_1, \dots, x_n)$ 为 (联合) 密度函数. 显然, 密度函数满足如下条件:

$$(1) p(x_1, \dots, x_n) \geq 0$$

$$(2)$$

$$\int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} p(y_1, \dots, y_n) dy_1 \cdots dy_n = 1$$

在这里不多加赘述, 只是需要提及一下 n 维正态分布的形式。

设 $\mathbf{B} = (b_{ij})$ 为 n 维正定对称矩阵, $|\mathbf{B}|$ 为其行列式, \mathbf{B}^{-1} 为其逆,

又设 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$, $\mathbf{a} = (a_1, a_2, \dots, a_n)^T$, 则称

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} |\mathbf{B}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mathbf{a})^T \mathbf{B}^{-1} (\mathbf{x} - \mathbf{a}) \right\}$$

为 n 维正态密度函数. 若随机向量 ξ 具有此密度函数, 则称 ξ 服从 n 维正态分布, 记作 $\xi \sim N(\mathbf{a}, \mathbf{B})$

$n=1$ 时, $\mathbf{B} = \sigma^2$, $\mathbf{a} = \mu$, 得

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$n = 2$ 时, 记

$$\mathbf{B} = \begin{pmatrix} \sigma_1^2 & r\sigma_1\sigma_2 \\ r\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$$

其中 $\sigma_1, \sigma_2 > 0, |r| < 1, \mathbf{x} = (x, y)', \mathbf{a} = (a, b)'$. 则

$$\mathbf{B}^{-1} = \frac{1}{|\mathbf{B}|} \begin{pmatrix} \sigma_2^2 & -r\sigma_1\sigma_2 \\ -r\sigma_1\sigma_2 & \sigma_1^2 \end{pmatrix}$$

故可得

$$p(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-r^2}} \exp \left\{ -\frac{1}{2(1-r^2)} \left[\frac{(x-a)^2}{\sigma_1^2} - \frac{2r(x-a)(y-b)}{\sigma_1\sigma_2} + \frac{(y-b)^2}{\sigma_2^2} \right] \right\}$$

简记作 $(\xi, \eta) \sim N(a, b, \sigma_1^2, \sigma_2^2, r)$.

关于正态分布的更多详细内容见附录 C。

第四章 条件分布与独立性

4.1 随机变量的独立性

设 $F(x, y)$, $F_\xi(x)$ 和 $F_\eta(y)$ 分别为 (ξ, η) 的联合分布函数及其边际分布函数, 如果对一切 x, y 都有

$$F(x, y) = F_\xi(x)F_\eta(y)$$

成立, 则称 ξ 与 η 相互独立.

4.2 离散型随机变量的独立性

如果离散型随机向量 (ξ, η) 的联合分布列满足

$$P(\xi = x_i, \eta = y_j) = P(\xi = x_i)P(\eta = y_j), \quad i, j = 1, 2, \dots,$$

即

$$p_{ij} = p_{i\cdot} \cdot p_{\cdot j}$$

则称 ξ 与 η 相互独立 (independent). 否则, 称 ξ 与 η 相依 (dependent). 可以这么推导:

$$F(x, y) = P(\xi \leq x, \eta \leq y) = \sum_{x_i \leq x} \sum_{y_j \leq y} P(\xi = x_i, \eta = y_j)$$

$$F_\xi(x)F_\eta(y) = \sum_{x_i \leq x} P(\xi = x_i) \sum_{y_j \leq y} P(\eta = y_j)$$

根据

$$F(x, y) = F_\xi(x)F_\eta(y)$$

令 $x_1 < x_2 < \dots, y_1 < y_2 < \dots$, 有

$$F(x_1, y_1) = F_\xi(x_1)F_\eta(y_1)$$

即

$$p_{11} = p_{1\cdot} \cdot p_{\cdot 1}$$

考虑数学归纳, 如果 $p_{ij} = p_{i\cdot} \cdot p_{\cdot j}$ 对 $\forall i \leq m, j \leq n (i, j \in \mathbb{N}_+)$ 成立
那么根据

$$F(x_{m+1}, y_n) = F_\xi(x_{m+1})F_\eta(y_n)$$

有

$$\sum_{i \leq m+1} \sum_{j \leq n} p_{ij} = \sum_{i \leq m+1} p_{i\cdot} \sum_{j \leq n} p_{\cdot j}$$

根据已有条件, 除去相等项, 可以得到

$$p_{m+1,n} = p_{m+1,\cdot} \cdot p_{\cdot,n}$$

同理, 根据

$$F(x_m, y_{n+1}) = F_\xi(x_m)F_\eta(y_{n+1})$$

可以得到

$$p_{m,n+1} = p_{m,\cdot} \cdot p_{\cdot,n+1}$$

因此对于离散型随机变量, 用分布函数定义的随机变量的独立性条件

$$F(x, y) = F_\xi(x)F_\eta(y)$$

可以通过数学归纳推出其特有独立性条件

$$p_{ij} = p_{i\cdot} \cdot p_{\cdot j}$$

同理, 很方便地可以用后者反推出前者。因此在离散型随机变量中, 这两种定义是等价的。

4.3 连续型随机变量的独立性

设 $p(x, y)$ 与 $p_\xi(x), p_\eta(y)$ 分别为连续型随机向量 (ξ, η) 的联合密度和边际密度, 则 ξ, η 相互独立的充要条件是

$$p(x, y) = p_\xi(x)p_\eta(y)$$

证明: $\forall x, y,$

$$\begin{aligned}
 F(x, y) &= F_{\xi}(x)F_{\eta}(y) \\
 \iff \int_{-\infty}^x \int_{-\infty}^y p(u, v) du dv &= \int_{-\infty}^x p_{\xi}(u) du \int_{-\infty}^y p_{\eta}(v) dv \\
 \iff \int_{-\infty}^x \int_{-\infty}^y p(u, v) du dv &= \int_{-\infty}^x \int_{-\infty}^y p_{\xi}(u) p_{\eta}(v) du dv \\
 \iff p(x, y) &= p_{\xi}(x) p_{\eta}(y)
 \end{aligned}$$

4.4 离散型随机变量的条件分布

设 (ξ, η) 的联合分布列为 $P(\xi = x_i, \eta = y_j) = p_{ij}, i, j = 1, 2, \dots$. 若已知 $\xi = x_i (P(\xi = x_i > 0))$, 则

$$P(\eta = y_j | \xi = x_i) = \frac{P(\xi = x_i, \eta = y_j)}{P(\xi = x_i)} = \frac{p_{ij}}{p_{i\cdot}}, \quad j = 1, 2, \dots$$

即

$$p_{\eta|\xi}(y_j | x_i) = \frac{p_{ij}}{p_{i\cdot}}$$

如果令事件 $A = \{\eta = y_j\}$, $B = \{\xi = x_i\}$, 由乘法公式可知这是很自然的。

可见, ξ 和 η 相互独立的等价条件是

$$P(\eta = y_j | \xi = x_i) = P(\eta = y_j)$$

定义 $\xi = x_i$ 的条件下 η 的条件分布函数:

$$P(\eta \leq y | \xi = x_i) = \sum_{j: y_j \leq y} p_{\eta|\xi}(y_j | x_i)$$

4.5 连续性随机变量的条件分布

首先获得条件分布函数, 通过条件分布函数求导获得概率密度函数。

$$P(Y \leq y | X = x) = \lim_{\epsilon \rightarrow 0} P(Y \leq y | x - \epsilon < X \leq x + \epsilon) \quad (4.1)$$

$$= \lim_{\epsilon \rightarrow 0} \frac{P(Y \leq y, x - \epsilon < X \leq x + \epsilon)}{P(x - \epsilon < X \leq x + \epsilon)} \quad (4.2)$$

$$= \lim_{\epsilon \rightarrow 0} \frac{\frac{1}{2\epsilon} \int_{x-\epsilon}^{x+\epsilon} \int_{-\infty}^y p(u, v) du dv}{\frac{1}{2\epsilon} \int_{x-\epsilon}^{x+\epsilon} p_X(u) du} \quad (4.3)$$

$$= \frac{\int_{-\infty}^y p(x, v) dv}{p_X(x)} \quad (4.4)$$

求导得到

$$p_{Y|X}(y|x) = \frac{p(x, y)}{p_X(x)}$$

同理可以得到

$$p_{X|Y}(x|y) = \frac{p(x, y)}{p_Y(y)}$$

第五章 数学期望

5.1 离散型随机变量的数学期望

设离散型随机变量 $\xi \sim$

$$\begin{bmatrix} x_1 & x_2 & \cdots & x_n & \cdots \\ p(x_1) & p(x_2) & \cdots & p(x_n) & \cdots \end{bmatrix}$$

如果满足前提条件 $\sum_k x_k p_k$ 绝对收敛 ($\sum_k x_k p_k < \infty$)，则定义 **数学期望** (mathematical expectation) 或 **均值** (mean) 为

$$E\xi = \sum_k x_k p_k$$

(前提条件为了保证 $E\xi$ 的和不受求和次序的影响)

习题：计算泊松分布 ($\xi \sim \mathcal{P}(\lambda)$) 的数学期望

答案： $E\xi = \lambda$

5.2 连续型随机变量的数学期望

设连续型随机变量 ξ 有密度函数 $p(x)$ ，且满足前提条件

$$\int_{-\infty}^{+\infty} |x|p(x)dx < \infty$$

(即 $\int_{-\infty}^{+\infty} xp(x)dx$ 绝对收敛) 则称

$$E\xi = \int_{-\infty}^{+\infty} xp(x)dx$$

为 ξ 的数学期望。

无论是连续型还是离散型随机变量, 如果前提条件 (绝对收敛) 不满足, 都称数学期望不存在。

习题: 计算指数分布 ($\xi \sim \exp(\lambda)$) 的数学期望

答案: $E\xi = \frac{1}{\lambda}$

习题*: 计算正态分布 ($\xi \sim N(a, \sigma^2)$) 的数学期望

答案: $E\xi = a$, 过程可见附录 C

5.3 一般随机变量的数学期望

设连续型随机变量 ξ 有分布函数 $F(x)$, 且满足前提条件

$$\int_{-\infty}^{+\infty} |x| dF(x) < \infty$$

则称

$$E\xi = \int_{-\infty}^{+\infty} x dF(x)$$

为 ξ 的数学期望。前提条件若不满足, 则数学期望不存在。

需要注意的是, 这里的积分不是黎曼 (Riemann) 积分, 而是新定义的一种积分, 名为斯梯尔吉斯 (Stieltjes) 积分, 在此不加赘述。所以在此处可以稍稍看一看它的形式, 而不必直接计算, 因为很容易把黎曼积分的思想套在这个积分上, 而这是有可能出错的。(大佬可以忽视)

5.4 数学期望的性质

性质 1 $a \leq \xi \leq b \Rightarrow \exists E\xi, a \leq E\xi \leq b$

特别地, $\xi = c \Rightarrow E\xi = Ec = c$

性质 1' $|\xi| < \eta, \exists E\eta \Rightarrow \exists E\xi, |E\xi| \leq E|\xi| \leq E\eta$

性质 2 $\exists E\xi_1, \dots, E\xi_n \Rightarrow \forall$ 常数 c_1, \dots, c_n, b ,

$$\exists E \left(\sum_{i=1}^n c_i \xi_i + b \right)$$

且

$$E \left(\sum_{i=1}^n c_i \xi_i + b \right) = \sum_{i=1}^n c_i E\xi_i + b$$

特别地,

$$E\left(\sum_{i=1}^n \xi_i\right) = \sum_{i=1}^n E\xi_i, \quad E(c\xi) = cE\xi$$

性质 3 ξ_1, \dots, ξ_n 相互独立, $\exists E\xi_i, i = 1, \dots, n$, 则

$$E(\xi_1 \cdots \xi_n) = E\xi_1 \cdots E\xi_n$$

性质 4(有界收敛定理) 假设对任意 $\omega \in \Omega$ 有 $\lim_{n \rightarrow \infty} \xi_n(\omega) = \xi(\omega)$, 并且对一切 $n \geq 1$, $|\xi_n| \leq M$, 其中 M 为常数, 则

$$\lim_{n \rightarrow \infty} E\xi_n = E\xi$$

感兴趣的话可以自己证明一下。在这里象征性地证明一下最常用的性质 2:

$$E\left(\sum_{i=1}^n c_i \xi_i + b\right) = E(\xi + b) \cdots \cdots \xi = \sum_{i=1}^n c_i \xi_i \quad (5.1)$$

$$= \int_{-\infty}^{+\infty} (x + b) p_\xi(x) dx \quad (5.2)$$

$$= \int_{-\infty}^{+\infty} x p_\xi(x) dx + b \cdots \cdots \int_{-\infty}^{+\infty} p_\xi(x) dx = 1 \quad (5.3)$$

$$= \int_{R^n} \left(\sum_{i=1}^n c_i x_i \right) p_{\xi_1, \xi_2, \dots, \xi_n}(x_1, x_2, \dots, x_n) dx_1 dx_2 \cdots dx_n + b \quad (5.4)$$

$$= \sum_{i=1}^n \left(c_i \int_{R^n} x_i p_{\xi_1, \xi_2, \dots, \xi_n}(x_1, x_2, \dots, x_n) dx_1 dx_2 \cdots dx_n \right) + b \quad (5.5)$$

$$= \sum_{i=1}^n \left(c_i \int_{-\infty}^{+\infty} x_i p_{\xi_i}(x_i) dx_i \right) + b \quad (5.6)$$

$$= \sum_{i=1}^n c_i E\xi_i + b \quad (5.7)$$

以上证明是针对连续型随机变量。下面对离散型随机变量进行证明:

$$E\left(\sum_{i=1}^n c_i \xi_i + b\right) = E(\xi + b) \cdots \cdots \xi = \sum_{i=1}^n c_i \xi_i \quad (5.8)$$

$$= \sum_k (x_k + b)p_k \quad (5.9)$$

$$= \sum_k x_k p_k + b \cdots \cdots \sum_k p_k = 1 \quad (5.10)$$

$$= \sum_k \left(\sum_{i=1}^n c_i x_{ik} \right) p_k + b \quad (5.11)$$

$$= \sum_{i=1}^n c_i \sum_k x_{ik} p_k + b \quad (5.12)$$

$$= \sum_{i=1}^n c_i E\xi_i + b \quad (5.13)$$

注意到, 性质 2 其实就是线性性质。那么我们浮想联翩, 线性代数的 DNA 动了。建立一个线性空间 V , V 包括所有存在数学期望的一元随机变量。那么 $E: V \rightarrow R$ 就是一个线性变换。

进一步地, 我们定义一个内积: $\forall \alpha, \beta \in V, (\alpha, \beta) = E\alpha\beta$

首先根据内积的公理化定义验证它是内积。 $\forall \alpha, \beta, \gamma \in V, \forall \lambda \in \mathbb{R}$

(1) 正定性: $E\alpha^2 \geq 0$, 当且仅当 α 服从 $P(\alpha = 0) = 1$ 的退化分布时 (定义这种随机变量为这个线性空间的零元), 有 $E\alpha^2 = 0$

(2) 对称性: 显然有 $E\alpha\beta = E\beta\alpha$

(3) 加性: $E(\alpha + \beta)\gamma = E\alpha\gamma + E\beta\gamma$

(4) 齐性: $E(\lambda\alpha)\beta = \lambda E\alpha\beta$

加性和齐性由性质 2 证得。因此 $E\alpha\beta$ 可以成为线性空间 V 上的一个内积, 那么就有 Cauchy-Schwarz 不等式:

$$(E\alpha\beta)^2 \leq E\alpha^2 \cdot E\beta^2$$

特别地, $\forall X, Y \in V$, 有 $\exists EX, EY$, 则 $\exists E(X - EX), E(Y - EY)$, 则 $X - EX, Y - EY \in V$, 有

$$E(X - EX)(Y - EY) \leq (E(X - EX)^2 E(Y - EY)^2)^{1/2}$$

这将是下一节 Pearson 相关系数一个重要性质的依据。

5.5 条件期望

进入二元关联的考虑, 给定不同的 $\eta = y$, $\xi = x$ 的后验概率有所不同, 因而会影响其期望。这种情况下的期望就成为条件期望。

当然, 需要注意这里是用离散型随机变量举例进行的一个理解, 并不严格。如连续型随机变量的期望还需定义。

一般地, 若 $\eta = y$ 时, ξ 有条件分布函数 $F_{\xi|\eta}(x|y)$, 那么定义随机变量 ξ 的此时的条件期望为

$$E(\xi|\eta = y) = \int_{-\infty}^{+\infty} x dF_{\xi|\eta}(x|y)$$

对于离散型随机变量, 可以导出其条件期望:

$$E(\xi|\eta = y) = \sum_i x_i p_{\xi|\eta}(x|y) = \sum_i x_i P(\xi = x|\eta = y)$$

对于连续型随机变量, 可以导出其条件期望:

$$E(\xi|\eta = y) = \int_{-\infty}^{+\infty} x p_{\xi|\eta}(x|y) dx$$

5.6 全期望公式

全期望公式是一个很有趣的公式, 它可以写成

$$E(\xi) = E[E(\xi|\eta)]$$

在连续型随机变量的情况下, 我们可以做一个简单的推导

$$E[E(\xi|\eta)] = \int_{-\infty}^{+\infty} E(\xi|\eta) p_Y(y) dy \quad (5.14)$$

$$= \int_{-\infty}^{+\infty} \left(\int_{-\infty}^{+\infty} x p_{\xi|\eta}(x|y) dx \right) p_Y(y) dy \quad (5.15)$$

$$= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x \frac{p(x, y)}{p_Y(y)} \cdot p_Y(y) dx dy \quad (5.16)$$

$$= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x p(x, y) dx dy \quad (5.17)$$

$$= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x p(x, y) dy dx \quad (5.18)$$

$$= \int_{-\infty}^{+\infty} x p_X(x) dx = E(\xi) \quad (5.19)$$

在离散型随机变量的情况下,

$$E[E(\xi|\eta)] = \sum_j E(\xi|\eta)P(\eta = y_j) \quad (5.20)$$

$$= \sum_j \left(\sum_i x_i P(\xi = x_i|\eta = y_j) \right) P(\eta = y_j) \quad (5.21)$$

$$= \sum_j \sum_i x_i P(\xi = x_i|\eta = y_j) P(\eta = y_j) \quad (5.22)$$

$$= \sum_i x_i \left(\sum_j P(\xi = x_i|\eta = y_j) P(\eta = y_j) \right) \quad (5.23)$$

$$= \sum_i x_i P(\xi = x_i) = E(\xi) \quad (5.24)$$

条件期望也有一系列性质, 在此不再列举, 只举其比较有趣的性质: Cauchy-Schwarz 不等式:

$$E(XY|Z) \leq \sqrt{E(X^2|Z)} \sqrt{E(Y^2|Z)}$$

条件期望是具有线性的(显然, 可以自己写写), 那么内积的齐性和加性就满足了。对称性和正定性当然也满足。那么定义二元运算

$$(X, Y) = E(XY|Z)$$

就成为一种 V 上的内积。(V 就是 5.5.4 末尾定义的线性空间) 所以根据内积的 Cauchy-Schwarz 不等式就可以得证。

第六章 方差、协方差与相关系数

6.1 方差及其性质

6.1.1 方差

一切为了描述数据的离散程度！

离差 (deviation): $\xi - E\xi$

离差取期望时，只要 ξ 期望存在，那么将会正负相消。因此考虑

方差 (variance): $E(\xi - E\xi)^2$ 来描述期望的离散程度，即

$$Var\xi(D\xi) = E(\xi - E\xi)^2, \text{ 当它存在且为有限值时}$$

为统一量纲，有时使用**标准差 (standard deviation):** $\sqrt{Var\xi}$

计算方差可以直接使用定义，也可以使用重要的**方差公式:**

$$Var\xi = E\xi^2 - (E\xi)^2$$

证明:

$$E(\xi - E\xi)^2 = E(\xi^2 - 2\xi E\xi + (E\xi)^2) \quad (6.1)$$

$$= E\xi^2 - 2E\xi \cdot E\xi + (E\xi)^2 \quad (6.2)$$

$$= E\xi^2 - (E\xi)^2 \quad (6.3)$$

6.1.2 切比雪夫 (Chebyshev) 不等式

若随机变量 ξ 的方差存在, 则 $\forall \varepsilon > 0$ 有

$$P(|\xi - E\xi| \geq \varepsilon) \leq \frac{Var\xi}{\varepsilon^2}$$

证明设 ξ 的分布函数为 $F(x)$, 则

$$\begin{aligned} P(|\xi - E\xi| \geq \varepsilon) &= \int_{|x - E\xi| \geq \varepsilon} dF(x) \\ &\leq \int_{|x - E\xi| \geq \varepsilon} \frac{(x - E\xi)^2}{\varepsilon^2} dF(x) \\ &\leq \frac{1}{\varepsilon^2} \int_{-\infty}^{\infty} (x - E\xi)^2 dF(x) \\ &= \frac{Var\xi}{\varepsilon^2} \end{aligned}$$

根据切比雪夫不等式, 可以利用方差粗糙估计随机变量落在偏离均值一定范围内的概率。

6.1.3 方差的性质

性质 1 $Var\xi = 0$ 的充要条件是 $P(\xi = c) = 1$, 其中 c 是常数.

证明: 显然条件充分. 反之, 如果 $Var\xi = 0$, 记 $E\xi = c$, 由切比雪夫不等式

$$P(|\xi - E\xi| \geq \varepsilon) = 0$$

对 $\forall \varepsilon > 0$ 成立. 从而

$$P(\xi = c) = 1 - P(|\xi - c| > 0) \tag{6.4}$$

$$= 1 - \lim_{n \rightarrow \infty} P\left(|\xi - c| > \frac{1}{n}\right) = 1 \tag{6.5}$$

性质 2 设 c, b 都是常数, 则

$$Var(c\xi + b) = c^2 Var\xi$$

证明:

$$Var(c\xi + b) = E(c\xi + b - E(c\xi + b))^2 \tag{6.6}$$

$$= E(c\xi + b - cE\xi - b)^2 \tag{6.7}$$

$$= c^2 E(\xi - E\xi)^2 = c^2 Var\xi \tag{6.8}$$

性质 3 若 $c \neq E\xi$, 则 $Var\xi < E(\xi - c)^2$.

证明: 注意到

$$Var\xi = E\xi^2 - (E\xi)^2$$

和

$$E(\xi - c)^2 = E\xi^2 - 2cE\xi + c^2$$

两边相减得

$$\text{Var}\xi - E(\xi - c)^2 = -(E\xi - c)^2 < 0$$

这说明随机变量 ξ 对数学期望 $E\xi$ 的离散度最小.

性质 4

$$\text{Var}\left(\sum_{i=1}^n \xi_i\right) = \sum_{i=1}^n \text{Var}\xi_i + 2 \sum_{1 \leq i < j \leq n} E(\xi_i - E\xi_i)(\xi_j - E\xi_j)$$

特别地, 若 $\xi_1, \xi_2, \dots, \xi_n$ 两两独立, 则

$$\text{Var}\left(\sum_{i=1}^n \xi_i\right) = \sum_{i=1}^n \text{Var}\xi_i$$

证明:

$$\text{Var}\left(\sum_{i=1}^n \xi_i\right) = E\left(\sum_{i=1}^n \xi_i - E\sum_{i=1}^n \xi_i\right)^2 = E\left(\sum_{i=1}^n (\xi_i - E\xi_i)\right)^2 \quad (6.9)$$

$$= E\left[\sum_{i=1}^n (\xi_i - E\xi_i)^2 + 2 \sum_{1 \leq i < j \leq n} (\xi_i - E\xi_i)(\xi_j - E\xi_j)\right] \quad (6.10)$$

$$= \sum_{i=1}^n \text{Var}\xi_i + 2 \sum_{1 \leq i < j \leq n} E(\xi_i - E\xi_i)(\xi_j - E\xi_j) \quad (6.11)$$

当 $\xi_1, \xi_2, \dots, \xi_n$ 两两独立时, 易证 $\xi_1 - E\xi_1, \dots, \xi_n - E\xi_n$ 也两两独立, 故

$$E(\xi_i - E\xi_i)(\xi_j - E\xi_j) = E(\xi_i - E\xi_i) \cdot E(\xi_j - E\xi_j) = 0$$

交叉项为 0, 则成立

$$\text{Var}\left(\sum_{i=1}^n \xi_i\right) = \sum_{i=1}^n \text{Var}\xi_i$$

习题: 求二项分布 ($\xi \sim B(n, p)$) 的方差

答案: $\text{Var}\xi = npq$ (提示: $\xi = \sum_{i=1}^n \xi_i$, ξ_i 服从两点分布且相互独立)

习题*: 求一元正态分布 ($\xi \sim N(a, \sigma^2)$) 的方差

答案: $\text{Var}\xi = \sigma^2$, 详细过程见附录 C

6.2 协方差及其性质

6.2.1 协方差

对于随机向量，需要研究各分量之间的关系。

设 ξ_i 和 ξ_j 的联合分布函数为 $F_{ij}(x, y)$. 若 $E|(\xi_i - E\xi_i)(\xi_j - E\xi_j)| < \infty$, 称

$$E(\xi_i - E\xi_i)(\xi_j - E\xi_j) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - E\xi_i)(y - E\xi_j) dF_{ij}(x, y)$$

为 ξ_i 和 ξ_j 的**协方差** (covariance), 记作 $Cov(\xi_i, \xi_j)$.

因此协方差就是方差性质 4 当中的交叉项, 因此方差性质 4 可以改写为

$$Var\left(\sum_{i=1}^n \xi_i\right) = \sum_{i=1}^n Var\xi_i + 2 \sum_{1 \leq i < j \leq n} Cov(\xi_i, \xi_j)$$

6.2.2 协方差的性质

性质 1 $Cov(\xi, \eta) = Cov(\eta, \xi) = E\xi\eta - E\xi E\eta$

性质 2 设 a, b 是常数, 则

$$Cov(a\xi, b\eta) = abCov(\xi, \eta)$$

性质 3 $Cov\left(\sum_{i=1}^n \xi_i, \eta\right) = \sum_{i=1}^n Cov(\xi_i, \eta)$.

协方差阵

对于 n 维随机向量 $\xi = (\xi_1, \dots, \xi_n)'$, 可定义它的协方差阵如

$$B = E(\xi - E\xi)(\xi - E\xi)^T = \begin{bmatrix} b_{11} & b_{12} & \cdots & b_{1n} \\ b_{21} & b_{22} & \cdots & b_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ b_{n1} & b_{n2} & \cdots & b_{nn} \end{bmatrix}$$

其中

$$b_{ij} = \begin{cases} Cov(\xi_i, \xi_j), & i \neq j \\ Var(\xi_i), & i = j \end{cases}$$

由上面的性质可知 \mathbf{B} 是一个对称阵, 且对任何实数 $t_j, j = 1, 2, \dots, n$, 二次型

$$[t_1, t_2, \dots, t_n] \begin{bmatrix} b_{11} & b_{12} & \cdots & b_{1n} \\ b_{21} & b_{22} & \cdots & b_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ b_{n1} & b_{n2} & \cdots & b_{nn} \end{bmatrix} \begin{bmatrix} t_1 \\ t_2 \\ \vdots \\ t_n \end{bmatrix} = \sum_{j,k} b_{jk} t_j t_k$$

$$\sum_{j,k} b_{jk} t_j t_k = \sum_{j,k} t_j t_k E(\xi_j - E\xi_j)(\xi_k - E\xi_k) \quad (6.12)$$

$$= E \left(\sum_{j=1}^n t_j (\xi_j - E\xi_j) \right)^2 \geq 0 \quad (6.13)$$

即随机向量 ξ 的协方差阵 \mathbf{B} 是非负定的.

性质 4 设

$$\xi = (\xi_1, \xi_2, \dots, \xi_n)^T, \quad \mathbf{C} = \begin{bmatrix} C_{11} & C_{12} & \cdots & C_{1n} \\ C_{21} & C_{22} & \cdots & C_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ C_{n1} & C_{n2} & \cdots & C_{nn} \end{bmatrix}$$

则 $C\xi$ 的协方差阵为 \mathbf{CBC}^T , 其中 \mathbf{B} 是 ξ 的协方差阵。因为

$$EC(\xi - E\xi)(C(\xi - E\xi))^T = \mathbf{CBC}^T$$

性质 5 设 $\xi = (\xi_1, \xi_2, \dots, \xi_n)^T \sim N(\mu, B)$, 其中 μ 为 n 维向量, B 为 $n \times n$ 正定对称矩阵, 则 ξ 的数学期望为 μ , 协方差矩阵为 B 。

特别地, 当 $\mu = 0, B = I$ 时, $\xi_1, \xi_2, \dots, \xi_n$ 为相互独立的标准正态随机变量,

有 $E\xi_i = 0, \text{Var}(\xi_i) = 1, \text{Cov}(\xi_i, \xi_j) = 0, i \neq j$ 。即 $E\xi = 0_{n \times 1}$, 协方差矩阵为 I 。

一般地, 设 $T: V \rightarrow V, \mathcal{M}(T) = B$, V 是所有 n 元服从正态分布的随机向量构成的线性空间。由于 B 为正定对称矩阵, \exists 正的实特征值 $\lambda_1, \lambda_2, \dots, \lambda_n$ 和正交矩阵 Q 使得

$$B = Q^T \text{diag}\{\lambda_1, \lambda_2, \dots, \lambda_n\} Q \quad (6.14)$$

$$= Q^T D^2 Q \quad (\text{令 } D = \text{diag}\{\sqrt{\lambda_1}, \sqrt{\lambda_2}, \dots, \sqrt{\lambda_n}\}) \quad (6.15)$$

$$= Q^T D(QQ^T)DQ \quad (6.16)$$

$$= (Q^T DQ)(Q^T DQ) \quad (6.17)$$

令 $L = Q^T D Q$, 则 $B = L^2$ 。考虑 L 的特征多项式 $f(\lambda)$:

$$f(\lambda) = |\lambda E - L| = |\lambda Q^T Q - Q^T D Q| = |Q^T| \cdot |\lambda E - D| \cdot |Q| = \prod_{i=1}^n (\lambda - \sqrt{\lambda_i})$$

因此 $\sqrt{\lambda_1}, \sqrt{\lambda_2}, \dots, \sqrt{\lambda_n}$ 是 L 的 n 个正的实特征值, 可知 L 也是正交对称矩阵。

所以 $B = L^2 = LL^T = LLL^T$ 。令 $\eta = L^{-1}(\xi - \mu)$, 则 ξ 可以分解为 $\xi = L\eta + \mu$ 。

可以证明, 这样分解得到的 η 服从标准正态分布, 即 $\eta = L^{-1}(\xi - \mu) \sim N(0, I)$, $E\eta = 0$, 协方差矩阵为单位矩阵 I 。

6.3 Pearson 相关系数及其性质

6.3.1 Pearson 相关系数

令 $\xi^* = \frac{\xi - E\xi}{\sqrt{\text{Var}\xi}}, \eta^* = \frac{\eta - E\eta}{\sqrt{\text{Var}\eta}}$. 称

$$r_{\xi\eta} = \text{Cov}(\xi^*, \eta^*) = \frac{E(\xi - E\xi)(\eta - E\eta)}{\sqrt{\text{Var}\xi}\sqrt{\text{Var}\eta}}$$

为 ξ, η 的 Pearson 相关系数 (correlation coefficient)。

6.3.2 Pearson 相关系数的性质

上一节的末尾, 已经证明得到

$$E(X - EX)(Y - EY) \leq (E(X - EX)^2 E(Y - EY)^2)^{1/2}$$

因此显然可以得到性质 1。

性质 1 对相关系数 $r_{\xi\eta}$ 有

$$|r_{\xi\eta}| \leq 1$$

结合空间向量几何相关知识, $r_{\xi\eta} = 1$ 当且仅当

$$P\left(\frac{\xi - E\xi}{\sqrt{\text{Var}\xi}} = \frac{\eta - E\eta}{\sqrt{\text{Var}\eta}}\right) = 1$$

$r_{\xi\eta} = -1$ 当且仅当

$$P\left(\frac{\xi - E\xi}{\sqrt{\text{Var}\xi}} = -\frac{\eta - E\eta}{\sqrt{\text{Var}\eta}}\right) = 1$$

由性质 1, $r_{\xi\eta} = \pm 1$ 时, ξ 与 η 存在线性关系。

另一个极端情形, 定义 $r_{\xi\eta} = 0$ 时, ξ 与 η **不相关** (uncorrelated).

性质 2 对随机变量 ξ 和 η , 如果它们的方差有限, 则下列事实等价:

- (1) $\text{Cov}(\xi, \eta) = 0$;
- (2) ξ 与 η 不相关;
- (3) $E\xi\eta = E\xi E\eta$;
- (4) $\text{Var}(\xi + \eta) = \text{Var}\xi + \text{Var}\eta$.

证明: 显然 (1) 与 (2) 等价. 又由协方差的性质 1 得 (1) 与 (3) 等价.

$\text{Var}(\xi + \eta) = \text{Var}(\xi) + \text{Var}(\eta) + \text{Cov}(\xi, \eta)$ (方差性质 4), 得 (1) 与 (4) 等价.

性质 3 若 ξ 与 η 独立, 且它们的方差有限, 则 ξ 与 η 不相关.

显然, 由 ξ 与 η 独立知 (3) 成立, 从而 ξ 与 η 不相关. 但其逆不真.

例设随机变量 θ 服从均匀分布 $U(0, 2\pi)$. $\xi = \cos \theta, \eta = \sin \theta$. 显然 $\xi^2 + \eta^2 = 1$, 故 ξ 与 η 不独立. 但

$$\begin{aligned} E\xi &= E \cos \theta = \int_0^{2\pi} \frac{1}{2\pi} \cos \varphi d\varphi = 0 \\ E\eta &= E \sin \theta = \int_0^{2\pi} \frac{1}{2\pi} \sin \varphi d\varphi = 0 \\ E\xi\eta &= E \sin \theta \cos \theta = \int_0^{2\pi} \frac{1}{2\pi} \sin \varphi \cos \varphi d\varphi = 0 \end{aligned}$$

即 $E\xi\eta = E\xi E\eta$, ξ 与 η 不相关. 因此独立条件强于不相关, 独立一定不相关, 不相关不一定独立.

性质 4 对二元正态随机向量, 两个分量不相关与独立是等价的

习题 *: 证明性质 4. 详解可见附录 C.

第七章 矩

定义 k 阶原点矩

$$m_k = E\xi^k$$

数学期望就是一阶原点矩，另外在方差公式 $Var\xi = E\xi^2 - (E\xi)^2$ 中我们经常用到的 $E\xi^2$ 就是二阶原点矩。

原点矩简称为矩，可以对比力学中计算力矩时参考点选在 origin 时的情况，不过力学的力矩仅是一阶原点矩，二阶原点矩或许要用能量进行类比。但我们这里并不尝试直接阐明其应用（因为我目前也还不知道），仅先讲清楚这些抽象概念。

相对应地，参考点可以不选在 origin，这样参考点和 origin 就会有偏移。此时就需要定义 k 阶中心矩

$$c_k = E(\xi - E\xi)^k$$

从定义可以知道，一阶中心矩总是 0，二阶中心矩就是方差。其他常用的中心矩有三阶中心矩和四阶中心矩，可以用来表示随机变量分布函数的形状。

如偏态系数 (Coefficient of Skewness)，衡量随机变量分布的对称性。大于 0 表示正偏态，小于 0 表示负偏态。

$$Cs = \frac{c_3}{c_2^{1.5}}$$

峰态系数 (Coefficient of Kurtosis)，衡量均值处峰值高低，若大于 0 表明比正态分布更尖锐。

$$Ck = \frac{c_4}{c_2^2} - 3$$

对于正态分布 $\xi \sim N(\mu, \sigma^2)$ ，其偏态系数和峰态系数都是 0。其 k 阶中心矩都存在。考虑到正态分布 $\xi \sim N(\mu, \sigma^2)$ 的 k 阶中心矩其实就是 $\eta \sim N(0, \sigma^2)$ 的 k 阶原点矩，因此有

$$E(\xi - \mu)^{2k} = E\eta^{2k} = (2k - 1)!!\sigma^2, E(\xi - \mu)^{2k+1} = E\eta^{2k+1} = 0$$

第八章 特征函数

8.1 常见特征函数

8.1.1 退化分布

$$P(\xi = c) = 1$$

$$\varphi(t) = e^{ict}$$

8.1.2 二项分布

$$\xi \sim B(n, p)$$

$$\varphi(t) = (pe^{it} + q)^n$$

证明:

$$\varphi(t) = \sum_{k=0}^n \binom{n}{k} p^k q^{n-k} e^{itk} \quad (8.1)$$

$$= \sum_{k=0}^n \binom{n}{k} (pe^{it})^k q^{n-k} \quad (8.2)$$

$$= (pe^{it} + q)^n \quad (8.3)$$

(8.2) 到 (8.3) 使用了二项式定理。

8.1.3 泊松分布

$$\xi \sim \mathcal{P}(\lambda)$$

$$\varphi(t) = e^{\lambda(e^{it}-1)}$$

证明:

$$\varphi(t) = \sum_{k=0}^{\infty} e^{itk} \frac{\lambda^k}{k!} e^{-\lambda} \quad (8.4)$$

$$= \sum_{k=0}^{\infty} \frac{(\lambda e^{it})^k}{k!} e^{-\lambda} \quad (8.5)$$

$$= e^{\lambda e^{it}} \cdot e^{-\lambda} = e^{\lambda(e^{it}-1)} \quad (8.6)$$

8.1.4 均匀分布

$$\xi \sim U(a, b)$$

$$\varphi(t) = \frac{e^{ibt} - e^{iat}}{i(b-a)t}$$

证明:

$$\varphi(t) = \int_a^b e^{itx} \frac{1}{b-a} dx \quad (8.7)$$

$$= \frac{1}{i(b-a)t} e^{itx} \Big|_a^b \quad (8.8)$$

$$= \frac{e^{ibt} - e^{iat}}{i(b-a)t} \quad (8.9)$$

8.1.5 正态分布

$$\xi \sim N(\mu, \sigma^2)$$

$$\varphi(t) = e^{it\mu - \frac{\sigma^2 t^2}{2}}$$

证明:

$$\varphi(t) = \int_{-\infty}^{+\infty} e^{itx} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \quad (8.10)$$

$$\stackrel{\underline{\underline{y=\frac{x-\mu}{\sigma}}}}{=} \sigma e^{it\mu} \int_{-\infty}^{+\infty} e^{i(\sigma t)y} e^{-\frac{y^2}{2}} dy \quad (8.11)$$

考虑标准正态分布需要的积分

$$\int_{-\infty}^{+\infty} e^{itx} e^{-\frac{x^2}{2}} dx = \int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} \cos tx dx + i \int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} \sin tx dx \quad (8.12)$$

$$= \int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} \cos tx dx \quad (\text{第二个积分因奇函数为0}) \quad (8.13)$$

设 $g(t) = \int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} \cos tx dx$, 考虑求导

$$g'(t) = \frac{d}{dt} \left(\int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} \cos tx dx \right) \quad (8.14)$$

$$= - \int_{-\infty}^{+\infty} x e^{-\frac{x^2}{2}} \sin tx dx \quad (8.15)$$

$$= \int_{-\infty}^{+\infty} \sin tx d e^{-\frac{x^2}{2}} \quad (8.16)$$

$$= e^{-\frac{x^2}{2}} \sin tx \Big|_{-\infty}^{+\infty} - t \int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} \cos tx dx = -tg(t) \quad (8.17)$$

解微分方程

$$g'(t) = -tg(t) \quad (8.18)$$

$$\frac{dg}{g} = -tdt \quad (8.19)$$

$$g = Ae^{-\frac{t^2}{2}} \quad (8.20)$$

$$g(0) = \int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} dx = 1, \text{ 定得 } A = 1$$

因此有

$$\int_{-\infty}^{+\infty} e^{itx} e^{-\frac{x^2}{2}} dx = e^{-\frac{t^2}{2}}$$

则原 $\varphi(t)$ 有

$$\varphi(t) = e^{it\mu} \cdot e^{-\frac{\sigma^2 t^2}{2}} = e^{it\mu - \frac{\sigma^2 t^2}{2}}$$

8.2 可微性

8.2.1 预备知识

记

$$F(t) = \int_R f(x, t) p(x) dx$$

假定其存在, 然后以下的 $g \geq 0$ 需满足要求

$$\int_R g(x) p(x) dx < \infty$$

(1) $\exists g, s.t. \forall x, t$

$$|f(x, t)| < g(x)$$

对某个 x , 若

$$\lim_{t \rightarrow t_0} f(x, t) = f(x, t_0)$$

则

$$\lim_{t \rightarrow t_0} F(t) = F(t_0)$$

即 f 连续 $\Rightarrow F$ 关于 t 连续

(2) $\exists g, s.t. \forall x, t$

$$\left| \frac{\partial f(x, t)}{\partial t} \right| < g(x)$$

则

$$F'(t) = \int_R \frac{\partial f(x, t)}{\partial t} p(x) dx$$

8.2.2 可微性

现在令 $g(x) = |x|$, 由于预设 X 期望存在, 则

$$\int_{-\infty}^{+\infty} g(x) dF(x) = \int_{-\infty}^{+\infty} |x| dF(x) < \infty$$

对于特征函数

$$\varphi(t) = Ee^{itX} = \int_{-\infty}^{+\infty} e^{itx} dF(x)$$

令 $f(x, t) = e^{itx}$, 则

$$\left| \frac{\partial f(x, t)}{\partial t} \right| = \left| ix e^{itx} \right| \leq |x| = g(x)$$

那么就有

$$\varphi'(t) = \int_{-\infty}^{+\infty} \frac{\partial f(x, t)}{\partial t} dF(x) = i \int_{-\infty}^{+\infty} x e^{itx} dF(x)$$

特别地, 有

$$\varphi'(0) = i \int_{-\infty}^{+\infty} x dF(x) = i\mu$$

同理, 考虑 k 阶 (原点) 矩, 则若 $E|X|^k < \infty$, 则

$$\varphi^{(k)}(t) = i^k \int_{-\infty}^{+\infty} x^k e^{itx} dF(x)$$

那么原点处 $\varphi(x)$ 可做 k 次 Taylor 展开

$$\begin{aligned}\varphi(x) &= \varphi(0) + \varphi'(0)x + \frac{\varphi''(0)}{2!}x^2 + \cdots + \frac{\varphi^{(k)}(0)}{k!}x^k + o(t^k) \\ &= 1 + iEXt - \frac{1}{2}EX^2t^2 + \cdots + i^k \frac{EX^k}{k!}t^k + o(t^k)\end{aligned}$$

第九章 概率极限定理

9.1 Bernoulli 大数律

9.1.1 内容

$p \in (0, 1), S_n \sim B(n, p)$, 则

$$\frac{S_n}{n} \rightarrow p, \quad n \rightarrow \infty$$

即

$$P\left(\omega : \left|\frac{S_n(\omega)}{n} - p\right| > \varepsilon\right) \rightarrow 0, \quad n \rightarrow \infty$$

若引入依概率收敛的概念, 那么其实就是

$$\frac{S_n}{n} \xrightarrow{P} p, \quad n \rightarrow \infty$$

9.2 De Moivre-Laplace 中心极限定理

9.2.1 内容

$p \in (0, 1), S_n \sim B(n, p)$, 则

$$\frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow{d} N(0, 1)$$

这里是依分布收敛的概念。

9.3 Poisson 极限定理

$p_n \in (0, 1), S_n \sim B(n, p_n), np_n \rightarrow \lambda, \lambda \in (0, 1)$, 则

$$P(S_n = k) \rightarrow \frac{\lambda^k}{k!}, \quad k = 0, 1, 2, \dots, \quad n \rightarrow \infty$$

我猜想这里应该是依概率收敛。不过我也猜想这里不是重点。

9.4 Chebyshev 大数律

9.4.1 内容

ξ_k 是一列随机变量。 $E\xi_k = \mu$, $S_n = \sum_{k=1}^n \xi_k$, 如果有

$$\frac{Var(S_n)}{n^2} \rightarrow 0, \quad n \rightarrow \infty$$

那么

$$\frac{S_n}{n} \xrightarrow{P} \mu, n \rightarrow \infty$$

9.4.2 推广

$E\xi_k = \mu_k$, 则满足方差条件后有

$$\frac{S_n}{n} - \frac{\sum_{k=1}^n \mu_k}{n} \xrightarrow{P}, n \rightarrow \infty$$

9.4.3 回忆 Chebyshev 不等式

$\exists EX, EX^2$, 则 $\forall \varepsilon > 0$

$$P(|X - EX| > \varepsilon) \leq \frac{Var(X)}{\varepsilon^2}$$

可以用以证明 Bernoulli 大数律

$$P\left(\left|\frac{S_n}{n} - p\right| > \varepsilon\right) \leq \frac{Var\left(\frac{S_n}{n}\right)}{\varepsilon^2} \quad (9.1)$$

$$= \frac{Var(\sum_{k=1}^n \xi_k)}{n^2 \varepsilon^2} \quad (9.2)$$

$$= \frac{\sum_{k=1}^n Var(\xi_k)}{n^2 \varepsilon^2} \quad (9.3)$$

$$= \frac{p(1-p)}{n \varepsilon^2} \rightarrow 0, \quad n \rightarrow \infty \quad (9.4)$$

9.5 Khinchine 大数律

9.5.1 内容

ξ_k 独立同分布, $E\xi_k = \mu$, 则

$$\frac{S_n}{n} \rightarrow \mu, \quad n \rightarrow \infty$$

9.6 Levy-Feller 中心极限定理

9.6.1 内容

$\xi_k, k \geq 1$ 是一列 独立同分布随机变量, $E\xi_k = \mu, \text{Var}(\xi_k) = \sigma^2$. 记 $S_n = \sum_{k=1}^n \xi_k$, 则 $\forall x$,

$$P\left(\frac{S_n - n\mu}{\sigma\sqrt{n}} \leq x\right) \rightarrow \varphi(x)$$

即

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0, 1)$$

9.6.2 意义

(1) 应用于一般随机变量, 是 de Moivre-Laplace 中心极限定理的推广

(2) 说明测量误差可用正态分布描述

随机测量值 X_i , 均值 μ , 每次误差为 $X_i - \mu$, n 次观测叠加误差 (注意是离差不是方差, 可以相消) 为 $\sum_{i=1}^n (X_i - \mu)$, 则

$$\sum_{i=1}^n (X_i - \mu) \sim N(0, n\sigma^2), \quad n \gg 1$$

9.6.3 证明

组合计算失效, 使用特征函数方法。

9.7 Lyapunov 中心极限定理

9.7.1 内容

$\xi_k, k \geq 1$ 是一列 独立随机变量 (不一定同分布), $E\xi_k = \mu_k, \text{Var}(\xi_k) = \sigma_k^2$. 记 $S_n = \sum_{k=1}^n \xi_k, B_k = \sum_{k=1}^n \sigma_k^2$, 如果

$$(1) B_n \rightarrow \infty$$

$$(2) E(|X_k|^3) < \infty, \text{ 且}$$

$$\frac{\sum_{k=1}^n E|X_k|^3}{B_n^{\frac{3}{2}}} \rightarrow 0, \quad n \rightarrow \infty$$

则 $\forall x$,

$$P\left(\frac{\sum_{k=1}^n (\xi_k - \mu_k)}{\sqrt{B_n}} \leq x\right) \rightarrow \phi(x)$$

则

$$\frac{\sum_{k=1}^n (\xi_k - \mu_k)}{\sqrt{B_n}} \xrightarrow{d} N(0, 1)$$

第十章 概率论的收敛

10.1 依概率收敛

10.1.1 定义

在概率空间 (Ω, Σ, P) 中

10.1.2 敛散性判别法则

10.1.3 性质

4. 连续映射保持依概率收敛性

设 $f: \mathbf{R} \rightarrow \mathbf{R}$ 是连续映射, 则

$$X_n \xrightarrow{P} X \Rightarrow f(X_n) \xrightarrow{P} f(X)$$

10.2 依分布收敛

10.2.1 定义

$X, X_n, n \geq 1$ 是一列随机变量, 其分布函数分别为 $F, F_n, n \geq 1$

若对 $\forall F$ 的连续点 x ,

$$F_n(x) \rightarrow F(x), \quad n \rightarrow \infty$$

则有

$$X_n \xrightarrow{d} X$$

(1) 回顾 F 的基本条件: 左极限存在, 右连续

(2) F 若在 \mathbf{R} 上连续, 则 F_n 处处收敛于 F

(3) 如果 F 单调有界, 则不连续点最多可数个。

$$D_F = \{x : F(x) - F(x-0) > 0\} = \cup_{n=1}^{\infty} \{x : F(x) - F(x-0) \geq \frac{1}{n}\}$$

因为有界, $\{x : F(x) - F(x-0) \geq \frac{1}{n}\}$ 就是有限集; n 从 1 数到 ∞ , 则可数。

(4) F 的连续点集在 \mathbf{R} 上稠密

10.2.2 依概率收敛强于依分布收敛

(1) 依概率收敛 \Rightarrow 依分布收敛

即

$$X_n \xrightarrow{P} X \Rightarrow X_n \xrightarrow{d} X$$

证明: $\forall x \in \mathbf{R}, \varepsilon > 0$,

$$P(X_n \leq x) = P(X_n \leq x, X_n - X \geq -\varepsilon) + P(X_n \leq x, X_n - X < -\varepsilon)$$

然而,

$$P(X_n \leq x, X_n - X < -\varepsilon) \leq P(X_n - X < -\varepsilon) \rightarrow 0$$

则

$$\begin{aligned} \lim_{n \rightarrow \infty} \sup P(X_n \leq x) &= P(X_n \leq x, X_n - X \geq -\varepsilon) \\ &= P(-\varepsilon \leq X_n - X \leq x - X) \\ &\leq P(X \leq x + \varepsilon) \rightarrow P(X \leq x), \varepsilon \rightarrow 0 \end{aligned}$$

因为分布函数右连续所以可以直接这么趋向。然而分布函数只是左极限存在, 并不一定左连续, 所以有

同理,

$$\lim_{n \rightarrow \infty} \inf P(X_n \leq x) \geq P(X \leq x - \varepsilon) \rightarrow P(X < x), \varepsilon \rightarrow 0$$

但是在连续点, 就也左连续了, 那么就可以得到

$$\lim_{n \rightarrow \infty} P(X_n \leq x) = P(X \leq x)$$

也就得到了依分布收敛。

(2) 依概率收敛 \nRightarrow 依分布收敛

有反例：

设 Y 为非退化对称随机变量，则显然有

$$Y \stackrel{d}{=} -Y$$

那么令 $X_n = Y, X = Y$ ，则 $X, X_n, n \geq 1$ 分布相同，有

$$X_n \xrightarrow{d} X$$

然而

$$P(|X_n - X| > \varepsilon) = P(2|Y| > \varepsilon)$$

Y 不恒等于 0（否则就是退化分布了），那么 X_n 不依概率收敛到 X 对于退化分布，特别地，有

$$X_n \xrightarrow{d} c \Rightarrow X_n \xrightarrow{P} c$$

即退化分布情况下，依概率收敛和依分布收敛是等价的。

证明：

10.2.3 敛散性判别法则

Levy 连续性定理

$X, X_n, n \geq 1$ 是一列随机变量，其特征函数分别为 $\phi, \phi_n, n \geq 1$ ，则

$$X_n \xrightarrow{d} X \Rightarrow \phi_n(t) \rightarrow \phi(t), \quad t \in \mathbf{R}$$

另一种形式，如果

$$\phi_n(t) \rightarrow \phi(t), \quad t \in \mathbf{R}$$

且 ϕ 在 0 处连续，那么 ϕ 一定是特征函数，其对应的随机变量 X 满足

$$X_n \xrightarrow{d} X$$

可以认为是等价条件。

证明 Khinchine 大数律

分析：频数除以次数依概率收敛于期望，由于期望可以看成退化分布的随机变量，所以和按分布收敛于期望是等价的。

$\xi_k, k \geq 1$ 独立同分布， $E\xi_k = \mu$ 时，令 $X_n = \frac{1}{n} \sum_{k=1}^n \xi_k$ ，由独立性有

$$\begin{aligned}\phi_n(t) &= E \exp \left\{ i \frac{1}{n} \sum_{k=1}^n \xi_k t \right\} \\ &= \prod_{k=1}^n \left[E \exp \left\{ i \frac{1}{n} \xi_k t \right\} \right] \quad (\text{独立性}) \\ &= \left[E \exp \left\{ i \frac{1}{n} \xi_1 t \right\} \right]^n \quad (\text{同分布})\end{aligned}$$

对 $E \exp \left\{ i \frac{1}{n} \xi_1 t \right\}$ 进行泰勒展开，有

$$E \exp \left\{ i \frac{1}{n} \xi_1 t \right\} = 1 + i \frac{t}{n} \mu + o\left(\frac{t}{n}\right)$$

那么， $\forall t \in \mathbf{R}$,

$$\phi_n(t) = \left[1 + \frac{it\mu}{n} + o\left(\frac{t}{n}\right) \right]^n \rightarrow e^{it\mu}$$

显然 $e^{it\mu}$ 在 0 处连续，且对应常数为 μ 的退化分布，那么得证依分布收敛

证明 Levy-Feller 中心极限定理

$\xi_k, k \geq 1$ 独立同分布， $E\xi_k = \mu, \text{Var}(\xi_k) = \sigma^2$ ，那么

$$X_n = \frac{1}{\sigma\sqrt{n}} \sum_{k=1}^n (\xi_k - \mu) \xrightarrow{d} N(0, 1)$$

证明：只需证

$$\phi_n(t) = E \exp \{ it X_n \} \rightarrow \exp \left\{ -\frac{t^2}{2} \right\}$$

易得

$$\phi_n(t) = \left[E \exp \left\{ it \frac{\xi_1 - \mu}{\sigma\sqrt{n}} \right\} \right]^n$$

泰勒展开，有

$$E \exp \left\{ i \frac{t}{\sigma\sqrt{n}} (\xi_1 - \mu) \right\} = 1 + i \frac{t}{\sigma\sqrt{n}} E(\xi_1 - \mu) - \frac{t^2}{\sigma^2 n} E(\xi_1 - \mu)^2 + o\left(\frac{1}{n}\right)$$

第十一章 正态分布

11.1 一元正态分布密度函数的规范性

先考虑重要积分 $\int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} dx$ 的值

$$\left(\int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} dx \right)^2 = \int_{-\infty}^{+\infty} e^{-\frac{y^2}{2}} dy \int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} dx \quad (11.1)$$

$$= \iint_{R^2} e^{-\frac{x^2+y^2}{2}} dx dy \quad (11.2)$$

$$= \iint_{R^2} e^{-\frac{\rho^2}{2}} \rho d\rho d\theta \quad (11.3)$$

$$= \int_0^{2\pi} d\theta \int_0^{+\infty} e^{-\frac{\rho^2}{2}} \rho d\rho \quad (11.4)$$

$$= \int_0^{2\pi} d\theta \int_0^{+\infty} -e^{-\frac{\rho^2}{2}} d\left(-\frac{\rho^2}{2}\right) \quad (11.5)$$

$$= 2\pi \quad (11.6)$$

可得 $\int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} dx = \sqrt{2\pi}$

下证一元正态分布密度函数 $p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}$ 的规范性

$$\int_{-\infty}^{+\infty} p(x) dx = \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\} dx \quad (11.7)$$

$$\stackrel{t = \frac{x-\mu}{\sigma}}{=} \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{t^2}{2}\right\} dt = 1 \quad (11.8)$$

得证。

11.2 二元正态分布的边际分布与线性变换

11.2.1 二元正态分布的边际分布

考虑 $(X, Y) \sim N(a, \sigma_1, b, \sigma_2; r)$, 求 $p_X(x), p_Y(y)$

在二元正态分布的密度函数

$$p(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-r^2}} \exp \left\{ -\frac{1}{2(1-r^2)} \left[\frac{(x-a)^2}{\sigma_1^2} - \frac{2\rho(x-a)(y-b)}{\sigma_1\sigma_2} + \frac{(y-b)^2}{\sigma_2^2} \right] \right\}$$

的指数中对 y 配方, 可把 $p(x, y)$ 写成

$$p(x, y) = \frac{1}{\sqrt{2\pi}\sigma_1} \exp \left\{ -\frac{(x-a)^2}{2\sigma_1^2} \right\} \frac{1}{\sqrt{2\pi}\sigma_2\sqrt{1-r^2}} \exp \left\{ -\frac{\left[y-b - \frac{r\sigma_2}{\sigma_1}(x-a) \right]^2}{2\sigma_2^2(1-r^2)} \right\}$$

令

$$q(x, y) = \frac{1}{\sqrt{2\pi}\sigma_2\sqrt{1-r^2}} \exp \left\{ -\frac{\left[y-b - \frac{r\sigma_2}{\sigma_1}(x-a) \right]^2}{2\sigma_2^2(1-r^2)} \right\}$$

$$\int_{-\infty}^{+\infty} q(x, y) dy = \frac{1}{\sqrt{2\pi}\sigma_2\sqrt{1-r^2}} \int_{-\infty}^{+\infty} \exp \left\{ -\frac{\left[y-b - \frac{r\sigma_2}{\sigma_1}(x-a) \right]^2}{2\sigma_2^2(1-r^2)} \right\} dy \quad (11.9)$$

$$= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} e^{-\frac{t^2}{2}} dt \dots \dots t = \frac{y-b - \frac{r\sigma_2}{\sigma_1}(x-a)}{\sigma_2\sqrt{1-r^2}} = 1 \quad (11.10)$$

$$(11.11)$$

则

$$p_X(x) = \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}\sigma_1} \exp \left\{ -\frac{(x-a)^2}{2\sigma_1^2} \right\} q(x, y) dy \quad (11.12)$$

$$= \frac{1}{\sqrt{2\pi}\sigma_1} \exp \left\{ -\frac{(x-a)^2}{2\sigma_1^2} \right\} \quad (11.13)$$

同理

$$p_Y(y) = \frac{1}{\sqrt{2\pi}\sigma_2} \exp \left\{ -\frac{(y-b)^2}{2\sigma_2^2} \right\}$$

11.2.2 二元正态分布的线性变换

假设 $(X, Y) \sim N(\mu_1, \sigma_1^2, \mu_2, \sigma_2^2, \rho)$ 。定义

$$\begin{pmatrix} U \\ V \end{pmatrix} = A \cdot \begin{pmatrix} X \\ Y \end{pmatrix}, \quad A = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \text{可逆}$$

求 (U, V) 的分布密度

A 可逆, 则

$$\begin{pmatrix} X \\ Y \end{pmatrix} = A^{-1} \begin{pmatrix} U \\ V \end{pmatrix}$$

Jacobi 行列式

$$J = |A^{-1}| = |A|^{-1}$$

协方差矩阵 Σ , 随机向量 \vec{x} , 期望向量 $\vec{\mu}$

$$\Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}, \vec{x} = \begin{pmatrix} x \\ y \end{pmatrix}, \vec{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}$$

则

$$p_{X,Y}(x, y) = \frac{1}{2\pi|\Sigma|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2}(\vec{x} - \vec{\mu})^T \Sigma^{-1}(\vec{x} - \vec{\mu}) \right\}$$

随机向量 $\vec{u} = \begin{pmatrix} u \\ v \end{pmatrix}$

$$p_{U,V}(u, v) = \frac{1}{2\pi|\Sigma|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2}(A^{-1}\vec{u} - \vec{\mu})^T \Sigma^{-1}(A^{-1}\vec{u} - \vec{\mu}) \right\} |J| \quad (11.14)$$

$$= \frac{1}{2\pi|A^T \Sigma A|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2}(\vec{u} - A\vec{\mu})^T (A \Sigma A^T)^{-1}(\vec{u} - A\vec{\mu}) \right\} \quad (11.15)$$

则

$$(U, V) \sim N(A\vec{\mu}, A \Sigma A^T)$$

$$A\vec{\mu} = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \cdot \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} = \begin{pmatrix} a\mu_1 + b\mu_2 \\ c\mu_1 + d\mu_2 \end{pmatrix}$$

$A \Sigma A^T$ 不再展开, 那将会是个很长的可怕式子。

11.3 二元正态分布的条件分布和独立性

11.3.1 二元正态分布的条件分布

考虑 $(X, Y) \sim N(\mu_1, \sigma_1, \mu_2, \sigma_2; \rho)$, 求 $p_{X|Y}(x|y), p_{Y|X}(y|x)$

当然, 如果直接使用 C.2 中的配方结果, 就不需要下面这么麻烦地化简了。因为 C.2 中没有给出配方过程, 因此在这里稍微写得详细一点。

$$p_{X|Y}(x|y) = \frac{p(x, y)}{p_Y(y)} \quad (11.16)$$

$$= \frac{\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x-\mu_1)^2}{\sigma_1^2} - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right] \right\}}{\frac{1}{\sqrt{2\pi}\sigma_2} \exp \left\{ -\frac{(y-\mu_2)^2}{2\sigma_2^2} \right\}} \quad (11.17)$$

$$= \frac{\exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x-\mu_1)^2}{\sigma_1^2} - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right] \right\}}{\sqrt{2\pi(1-\rho^2)}\sigma_1 \exp \left\{ -\frac{(y-\mu_2)^2}{2\sigma_2^2} \right\}} \quad (11.18)$$

$$= \frac{1}{\sqrt{2\pi(1-\rho^2)}\sigma_1} \exp \left\{ -\frac{(x-\mu_1)^2}{2(1-\rho^2)\sigma_1^2} + \frac{2\rho(x-\mu_1)(y-\mu_2)}{2(1-\rho^2)\sigma_1\sigma_2} - \frac{\rho^2(y-\mu_2)^2}{2(1-\rho^2)\sigma_2^2} \right\} \quad (11.19)$$

$$= A_1 \exp \{ A_2 [(x-\mu_1)^2 - 2k\rho(x-\mu_1)(y-\mu_2) + k^2\rho^2(y-\mu_2)^2] \} \quad (11.20)$$

$$(A_1 = \frac{1}{\sqrt{2\pi(1-\rho^2)}\sigma_1}, A_2 = -\frac{1}{2(1-\rho^2)\sigma_1^2}, k = \frac{\sigma_1}{\sigma_2}) \quad (11.21)$$

$$= A_1 \exp \{ A_2 [(x-\mu_1) - \rho k(y-\mu_2)]^2 \} \quad (11.22)$$

$$= \frac{1}{\sqrt{2\pi(1-\rho^2)}\sigma_1} \exp \left\{ -\frac{[(x-\mu_1) - \rho \frac{\sigma_1}{\sigma_2}(y-\mu_2)]^2}{2(1-\rho^2)\sigma_1^2} \right\} \quad (11.23)$$

同理

$$p_{Y|X}(y|x) = \frac{1}{\sqrt{2\pi(1-\rho^2)}\sigma_2} \exp \left\{ -\frac{[(y-\mu_2) - \rho \frac{\sigma_2}{\sigma_1}(x-\mu_1)]^2}{2(1-\rho^2)\sigma_2^2} \right\}$$

11.3.2 二元正态分布的独立性等价条件

考虑独立性, 有结论

$$\rho = 0 \iff X, Y \text{ 相互独立} \iff p(x, y) = p_X(x)p_Y(y), \forall x, y$$

因为

$$p_X(x) = \frac{1}{\sqrt{2\pi}\sigma_1} \exp \left\{ -\frac{(x-\mu_1)^2}{2\sigma_1^2} \right\} \quad (11.24)$$

$$p_Y(y) = \frac{1}{\sqrt{2\pi}\sigma_2} \exp \left\{ -\frac{(y-\mu_2)^2}{2\sigma_2^2} \right\} \quad (11.25)$$

$$p(x, y) = \frac{1}{2\pi\sigma_1\sigma_2(1-\rho^2)}. \quad (11.26)$$

$$\exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x-\mu_1)^2}{\sigma_1^2} - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right] \right\} \quad (11.27)$$

$$p(x, y) = p_X(x)p_Y(y) \iff \quad (11.28)$$

$$\frac{1}{(1-\rho^2)} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{\rho^2(x-\mu_1)^2}{\sigma_1^2} - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{\rho^2(y-\mu_2)^2}{\sigma_2^2} \right] \right\} = 1 \quad (11.29)$$

$$\iff \rho^2 a^2 - 2\rho ab + \rho^2 b^2 = -2\sigma_1^2(1-\rho^2) \ln(1-\rho^2), \forall a = (x-\mu_1), b = \frac{\sigma_1}{\sigma_2}(y-\mu_2) \quad (11.30)$$

$\rho = 0$ 时, 显然反推成立。则考虑正推, 用反证法, 若 $\rho \in (-1, 0) \cup (0, 1)$

有

$$\rho a^2 - 2ab + \rho b^2 = -2\frac{\sigma_1^2}{\rho}(1-\rho^2) \ln(1-\rho^2) = C$$

设

$$f(a, b) = \rho a^2 - 2ab + \rho b^2, f(a, b) = C \Rightarrow \frac{\partial f}{\partial a} = 0, \frac{\partial f}{\partial b} = 0$$

$$\therefore \begin{cases} \frac{\partial f}{\partial a} = 2\rho a - 2b = 0 \\ \frac{\partial f}{\partial b} = 2\rho b - 2a = 0 \end{cases} \Rightarrow b = \rho a = \rho(\rho b) = \rho^2 b, (1-\rho^2)b = 0, b = 0$$

同理 $a = 0$

这与 a, b 任取, $f \equiv C$ 矛盾, 则假设不成立, 必有 $\rho = 0$

11.4 一元正态分布的期望与方差

设 $\xi \sim N(\mu, \sigma^2)$, 则其密度函数为

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x-\mu)^2}{2\sigma^2} \right\}$$

首先预备求两个积分: $\int_{-\infty}^{+\infty} x e^{-\frac{x^2}{2}} dx$ 和 $\int_{-\infty}^{+\infty} x^2 e^{-\frac{x^2}{2}} dx$

对于第一个积分, 由于被积函数是奇函数, 有:

$$\int_{-\infty}^{+\infty} x e^{-\frac{x^2}{2}} dx = 0$$

对于另外一个积分, 有:

$$\int_{-\infty}^{+\infty} x^2 e^{-\frac{x^2}{2}} dx = - \int_{-\infty}^{+\infty} x d(e^{-\frac{x^2}{2}}) = -x e^{-\frac{x^2}{2}} \Big|_{-\infty}^{+\infty} + \int_{-\infty}^{+\infty} e^{-\frac{x^2}{2}} dx = \sqrt{2\pi}$$

因为

$$\lim_{x \rightarrow \infty} x e^{-\frac{x^2}{2}} = \lim_{x \rightarrow \infty} \frac{x}{e^{\frac{x^2}{2}}} = \lim_{x \rightarrow \infty} \frac{1}{x e^{\frac{x^2}{2}}} = 0$$

考虑其期望, 有

$$EX = \int_{-\infty}^{+\infty} x \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x-\mu)^2}{2\sigma^2} \right\} dx \quad (11.31)$$

$$\stackrel{t=\frac{x-\mu}{\sigma}}{=} \int_{-\infty}^{+\infty} (\sigma t + \mu) \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt \quad (11.32)$$

$$= \sigma \int_{-\infty}^{+\infty} t \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt + \mu \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt \quad (11.33)$$

$$= \mu \quad (11.34)$$

考虑方差, 有

$$EX^2 = \int_{-\infty}^{+\infty} x^2 \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x-\mu)^2}{2\sigma^2} \right\} dx \quad (11.35)$$

$$\stackrel{t=\frac{x-\mu}{\sigma}}{=} \int_{-\infty}^{+\infty} (\sigma t + \mu)^2 \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt \quad (11.36)$$

$$= \frac{1}{\sqrt{2\pi}} \left(\sigma^2 \int_{-\infty}^{+\infty} t^2 e^{-\frac{t^2}{2}} dt + 2\sigma\mu \int_{-\infty}^{+\infty} t e^{-\frac{t^2}{2}} dt + \mu^2 \int_{-\infty}^{+\infty} e^{-\frac{t^2}{2}} dt \right) \quad (11.37)$$

$$= \sigma^2 + \mu^2 \quad (11.38)$$

则 $Var\xi = EX^2 - (EX)^2 = \sigma^2$

11.5 二元正态分布的协方差、Pearson 相关系数

$(\xi, \eta) \sim N(a, b, \sigma_1^2, \sigma_2^2, r)$, 求 $Cov(\xi, \eta)$ 和 $r_{\xi, \eta}$.

解

$$Cov(\xi, \eta) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x-a)(y-b)p(x, y)dx dy \quad (11.39)$$

$$= \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-r^2}} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x-a)(y-b) \quad (11.40)$$

$$\cdot \exp \left\{ -\frac{1}{2(1-r^2)} \left(\frac{x-a}{\sigma_1} - r \frac{y-b}{\sigma_2} \right)^2 - \frac{(y-b)^2}{2\sigma_2^2} \right\} dx dy \quad (11.41)$$

$$(11.42)$$

令

$$z = \frac{x-a}{\sigma_1} - r \frac{y-b}{\sigma_2}, \quad t = \frac{y-b}{\sigma_2}$$

则

$$\frac{x-a}{\sigma_1} = z + rt, \quad J = \frac{\partial(x, y)}{\partial(z, t)} = \sigma_1\sigma_2$$

于是

$$Cov(\xi, \eta) = \frac{\sigma_1\sigma_2}{2\pi\sqrt{1-r^2}} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (zt + rt^2) e^{-\frac{z^2}{2(1-r^2)}} e^{-\frac{t^2}{2}} dz dt \quad (11.43)$$

$$= \sigma_1\sigma_2 \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} t e^{-\frac{t^2}{2}} dt \frac{1}{\sqrt{2\pi\sqrt{1-r^2}}} \int_{-\infty}^{\infty} z e^{-\frac{z^2}{2(1-r^2)}} dz \quad (11.44)$$

$$+ \frac{r\sigma_1\sigma_2}{\sqrt{2\pi}} \int_{-\infty}^{\infty} t^2 e^{-\frac{t^2}{2}} dt \frac{1}{\sqrt{2\pi\sqrt{1-r^2}}} \int_{-\infty}^{\infty} e^{-\frac{z^2}{2(1-r^2)}} dz \quad (11.45)$$

$$= r\sigma_1\sigma_2 \quad (11.46)$$

故得

$$r_{\xi\eta} = \frac{Cov(\xi, \eta)}{\sqrt{\text{Var } \xi \text{Var } \eta}} = r$$

因此, ξ 与 η 不相关等价于 $r = 0$, 也就等价于 ξ 与 η 相互独立。